

# Shinybrms - rozszerzenie shiny do uprawiania statystyki Bayesowskiej

Marta Szuwarska

The logo for shinybrms, featuring a red hexagon with the text "shinybrms" in white lowercase letters.

shinybrms

# Wprowadzenie do statystyki Bayesowskiej

czyli co to za twór?

# Przykład 1





# Przykład 1



# Przykład 2

Kwiecień 2019



Styczeń 2021



# Przykład 2





# Przykład 3



# Twierdzenie Bayesa

*Niech  $A, B \in \mathcal{F}$  będą zdarzeniami oraz  $\mathbb{P}(B) > 0$ .*

*Wtedy:*

$$\mathbb{P}(A | B) = \frac{\mathbb{P}(B | A)\mathbb{P}(A)}{\mathbb{P}(B)}$$



# Twierdzenie Bayesa

*Niech  $\theta$  będzie wektorem parametrów.*

Wtedy:

$$\mathbb{P}(\theta \mid dane) = \frac{\mathbb{P}(dane \mid \theta) \mathbb{P}(\theta)}{\mathbb{P}(dane)}$$

# Twierdzenie Bayesa

*Niech  $\theta$  będzie wektorem parametrów.*

Wtedy:

Wiarygodność

Prawdopodobieństwo  
a priori

$$\mathbb{P}(\theta | dane) = \frac{\mathbb{P}(dane | \theta) \mathbb{P}(\theta)}{\mathbb{P}(dane)}$$

Prawdopodobieństwo  
a posteriori

Stała normalizująca

# Twierdzenie Bayesa

*Niech  $\theta$  będzie wektorem parametrów.*

Wtedy:

$$\mathbb{P}(\theta \mid dane) = \frac{\mathbb{P}(dane \mid \theta) \mathbb{P}(\theta)}{\mathbb{P}(dane)}$$


$$\mathbb{P}(\theta \mid dane) = \frac{\mathbb{P}(dane \mid \theta) \mathbb{P}(\theta)}{\int_{\Theta} \mathbb{P}(dane \mid \theta) \mathbb{P}(\theta) d\theta}$$



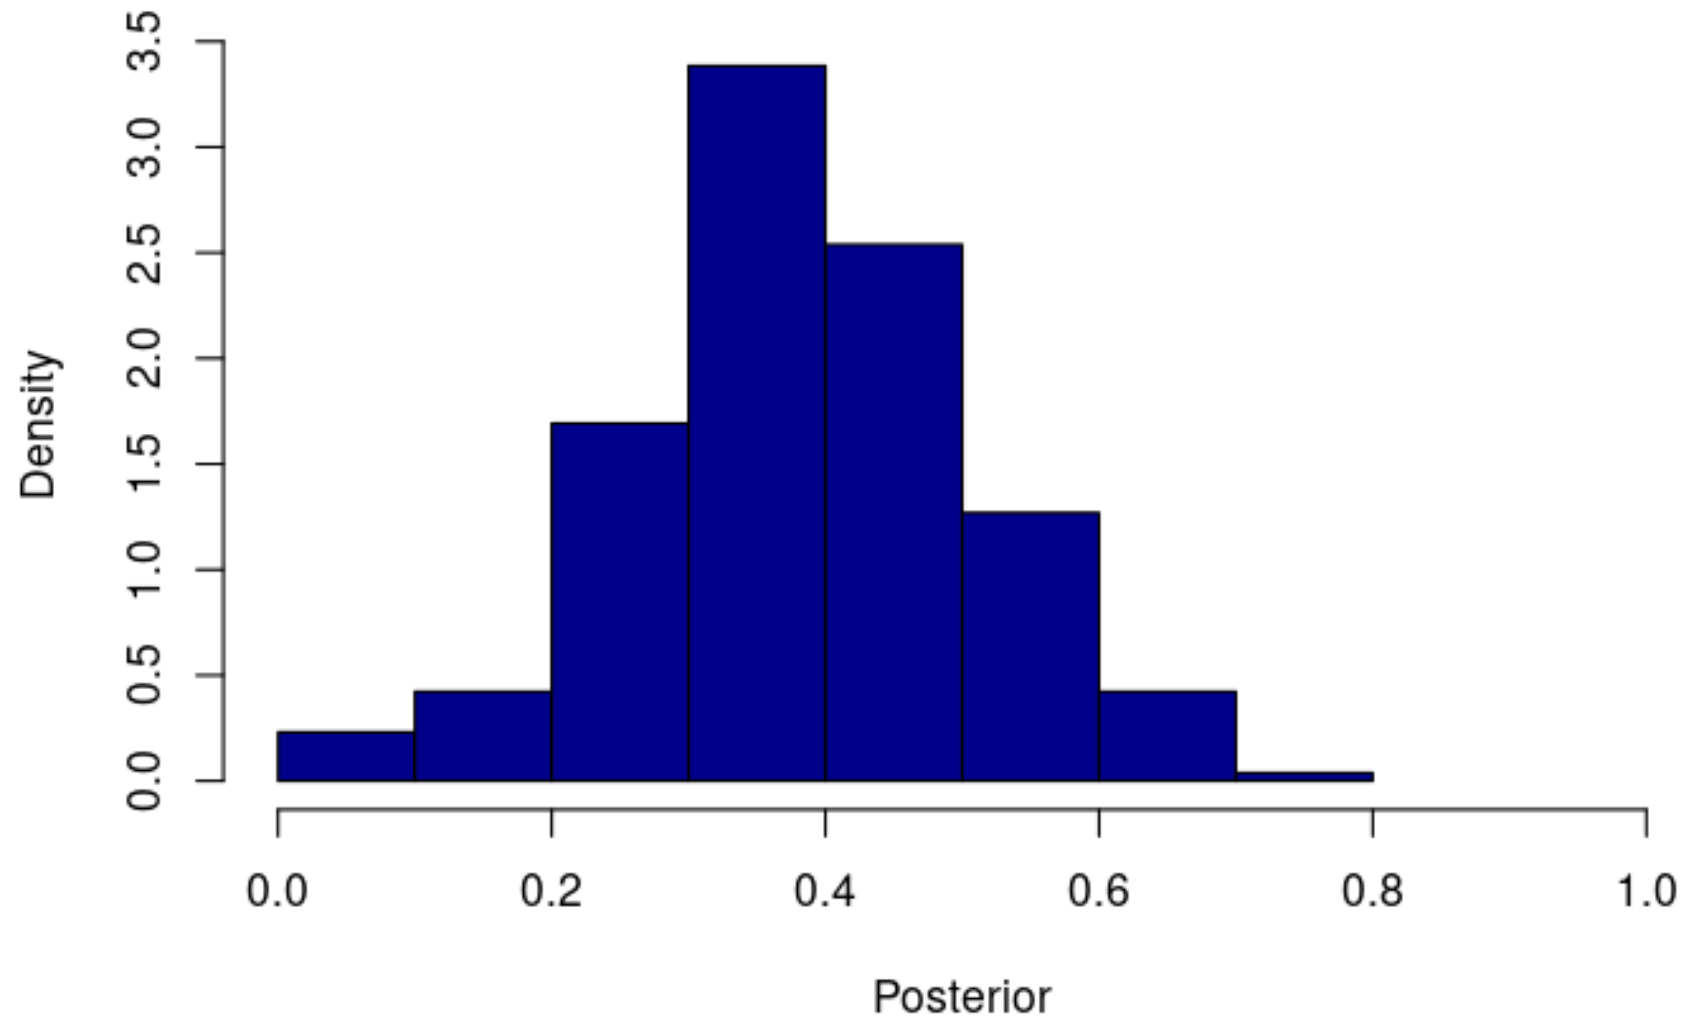
# A priori i a posteriori na przykładzie



**Histogram of Prior**




**Histogram of Posterior**





# Podejście Bayesowskie a klasyczne

Podejście klasyczne	Podejście Bayesowskie
Parametry ustalone	Parametry zmienne
Dane zmienne	Dane ustalone



# Zalety podejścia Bayesa

czyli dlaczego warto zostać bayesistą?

- Możliwość uwzględnienia wiedzy eksperckiej
- Możliwość łatwego narzucenia ograniczeń parametrów
- Możliwość wyliczenia pełnego rozkładu nawet przy mało licznym zbiorze
- Bardziej intuicyjna interpretacja wyników
- Łatwe wykluczenie parametrów zakłócających (*ang. nuisance parameters*)
- Rzadziej dochodzi do testowania istotności hipotezy zerowej
- Podejście bayesowskie nigdy nie jest gorsze niż klasyczne
- Można łatwo przeprowadzić diagnostykę modelu




# Stosowane algorytmy

czyli gdzie tu optymalizacja?

# Algorytmy MCMC

- Metropolis
- Metropolis-Hastings
- Próbnik Gibbsa
- Hamiltonian Monte Carlo
- no-U-turn sampler



# NUTS

- eksploruje rozkład w każdą stronę,
- nie musi wracać,
- jest bardziej efektywny niż tradycyjne algorytmy,
- automatycznie określa długość i kierunek symulowanych trajektorii.





# Powody powstania pakietu shinybrms

czyli czy naprawdę potrzebujemy kolejnego pakietu do R?

# Starsze pakiety

GUI name	Commercial	Algorithm (for inferring the posterior)							Algorithm choice
		Analytic	Non-MCMC			MCMC			
			Numerical	MC	BB	Non-HMC	Static HMC	NUTS	
WinBUGS (Lunn et al., 2000)	no	no	no	no	no	yes	no	no	no
OpenBUGS (Spiegelhalter et al., 2014)	no	no	no	no	no	yes	yes	no	no
BugsXLA (Woodward, 2011)	no	no	no	no	no	yes	yes	no	no
IBM SPSS Amos (Arbuckle, 2020)	yes	no	no	no	no	yes	yes	no	yes
TEET (Qian, 2011)	no <sup>(i)</sup>	yes	yes	yes	no	yes	no	no	no
JASP (JASP Team, 2022)	no	yes	yes	yes	no	yes	no	yes <sup>(ii)</sup>	no
BRNPM (Karabatsos, 2015, 2017)	no	no	no	no	no	yes	no	no	no
Stata (StataCorp, 2019b)	yes	no	no	no	no	yes	no	no	yes
BayES (Emvalomatis, 2020)	no	no	no	no	no	yes	no	no	no
IBM SPSS (IBM Corp., 2020)	yes	yes	yes	yes	no	no	no	no	no
BEsmarter (BEsmarter Team, 2020a,b; Ramírez-Hassan and Graciano-Londoño, 2021)	no	no	no	no	yes	yes	no	no	yes <sup>(iii)</sup>

# Testujemy apkę na przykładzie

czyli czy opatrunek z plazmy działa?

# Podsumowanie

czyli czy warto zainstalować pakiet shinybrms?

Dziękuję za uwagę